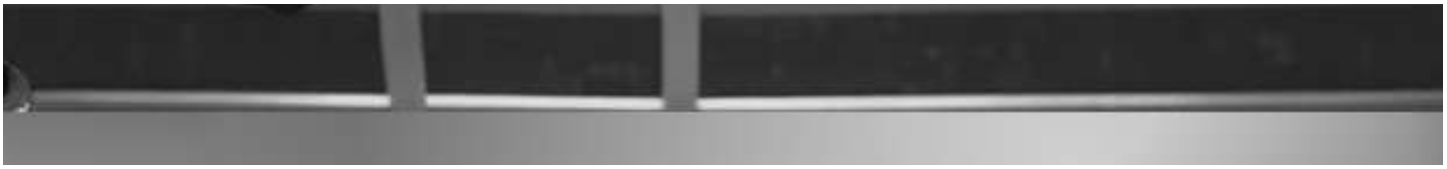
Data Lake vs Data Warehouse

10 min





05 DIAS : 01 HORAS : 08 MIN : 45 SEG Comece sua evolução

com o outro.

Por isso, ao longo desse artigo, vamos conhecê-los para entender quais são suas diferenças. Antes de começar esse assunto, porém, precisamos compreender um pouco sobre **estrutura de dados** para facilitar o entendimento do tema.

Acompanhe abaixo cada um dos conceitos e tenho certeza que, ao final deste artigo, você terá condições de aplicar cada um deles com maestria e assertividade, seja no seu ambiente de trabalho, seja em seus estudos cotidianos.

Tipos de dados

Em essência, dados são conjuntos de informações que podem ser coletadas, analisadas e utilizadas para tomar decisões, impulsionar inovações e compreender melhor o mundo ao nosso redor.

Eles são a matéria-prima do conhecimento no mundo digital - e seus formatos podem se apresentar em forma de tabelas, textos, imagens e até vídeos.

Por isso, é interessante classificá-los em categorias de tipos de dados. Acompanhe:

Estruturados

A primeira categoria são dados que possuem um padrão específico. Eles existem em formatos pré-definidos, como uma tabela com campos fixados. Além disso, dados estruturados são fáceis de analisar e pesquisar quando comparados com dados não-estruturados.

A **linguagem SQL** é utilizada para a consulta e construção de bases de dados estruturadas, que podem se relacionar com outras bases de dados também estruturadas. Exemplos de campos presentes em dados estruturados são: nomes, endereços, CEP, telefone, etc.

Não estruturados

A segunda categoria são dados não estruturados. Podem ter uma estrutura interna, mas não de uma forma pré-definida. Essa definição fica mais clara quando vemos que exemplos de dados não estruturados apresentam uma variedade maior.

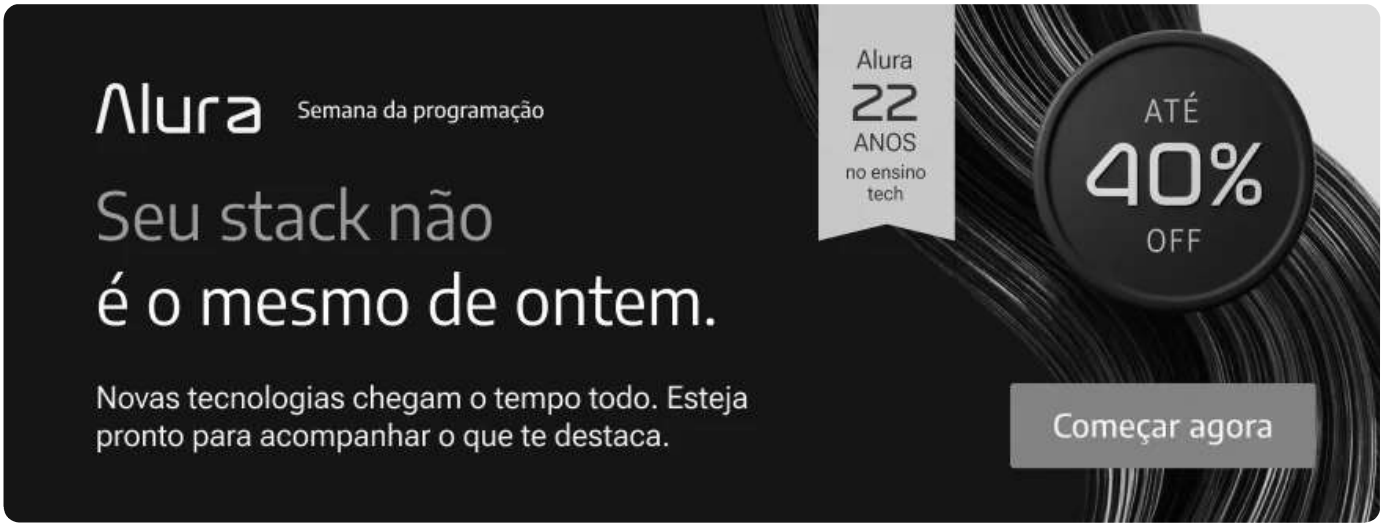
Nesse sentido, temos que texto, atividades em redes sociais, e-mails, gravações de câmeras de segurança e músicas são exemplos típicos de dados não estruturados. A variedade e falta de estrutura pré-definida torna a sua análise mais difícil. Além disso, por serem não estruturados, esses dados são armazenados em bancos de dados não relacionais, chamados de NoSQL.

Leia também: SQL e NoSQL: trabalhando com bancos relacionais e não relacionais

Semi estruturados

Dados semi-estruturados pertencem a uma terceira categoria que está entre as outras duas.

Eles podem ser pensados como um tipo de dado estruturado que não se encaixa na estrutura de uma base de dados relacional, mas que ainda considera sistemas de nomeação de campos, permitindo a separação de diferentes elementos e tornando a pesquisa mais fácil.



O que é Warehouse?

Agora que compreendemos o que são os dados e quais os tipos existentes, é fundamental entender o conceito de Warehouse. O termo em inglês pode ser traduzido para o português como "armazém", que nada mais é que um espaço físico ou uma instalação destinada ao armazenamento e gerenciamento de itens, onde são recebidos, organizados, estocados e posteriormente distribuídos conforme necessário.

No contexto de Big Data, um Data Warehouse é um sistema de armazenamento projetado especificamente para coletar, organizar e analisar grandes volumes de dados. Diferente de um armazém físico, um Data Warehouse é um repositório digital que agrupa dados provenientes de diversas fontes.

Tradicionalmente, ele é otimizado para lidar com dados estruturados, como registros financeiros, vendas e outras informações transacionais.

Embora um Data Warehouse possa acomodar dados semi-estruturados e não estruturados, sua principal força reside no armazenamento e na análise de dados estruturados. Ele é ideal para análises históricas e complexas, permitindo que as organizações realizem consultas intensivas e relatórios detalhados.

Ao contrário da noção de processamento em tempo real ou próximo do tempo real, os Data Warehouses são mais comumente usados para análises retrospectivas onde os dados já foram processados e organizados para consulta.

O que é um Sistema de Gerenciamento de Armazéns, ou ***Warehouse Management System*** (WMS)?

No contexto de um Data Warehouse, o WMS se refere a um conjunto de tecnologias e processos usados para gerenciar, organizar e utilizar eficientemente os dados armazenados no Data Warehouse.

Este sistema inclui ferramentas para a coleta, limpeza, integração e transformação de dados, além de capacidades de consulta, análise e geração de relatórios.

O objetivo é garantir que os dados dentro do Data Warehouse sejam de alta qualidade, facilmente acessíveis e úteis para análises de negócios e tomada de decisão. O WMS ajuda a otimizar a performance do armazenamento de dados, gerenciar o volume de dados, garantir a segurança dos dados e apoiar as necessidades de análise de dados das organizações.

Definição de Data Warehouse e Data Lake

Bases de dados são tipicamente estruturadas e organizadas para eventuais consultas, mas não são desenvolvidas para que possamos realizar a análise dos dados que as compõem.

A escolha de um Data Warehouse ou Data Lake pode estar relacionada aos dados que iremos extrair e aos procedimentos que realizaremos na sequência.

Por isso, precisamos entender em detalhes como cada um funciona.

O que é Data Warehouse

Um Data Warehouse é composto por diversas bases de dados - normalmente bases estruturadas, e é utilizado para o **business intelligence (BI)**. Por armazenarem dados processados, economizam espaço de armazenamento com dados que correm o risco de nunca serem usados.

Através do Data Warehouse, conseguimos consumir todas essas bases de dados e criar uma camada otimizada para realizar a análise de dados com ferramentas como o Power BI.

A organização dessas bases de dados (esquema) é feita durante a sua importação. Ele é uma ferramenta essencial para empresas que lidam com grandes volumes de dados, por permitir uma compreensão mais profunda dos padrões e tendências do negócio.

Data Warehouse — significado

O termo Data Warehouse, em inglês, pode ser traduzido de forma literal para o português como "Armazém de Dados", que representa bem o conceito dessa estrutura, que armazena informações e reúne dados de várias fontes e os organiza de maneira estruturada.

O que é Data lake

O Data Lake pode ser visto como um repositório centralizado para armazenar dados estruturados e não estruturados.

Ele pode armazenar dados não processados sem que haja a necessidade de nenhum tipo de transformação. Além disso, pode guardar qualquer tipo de formato, como imagens, textos, vídeos, modelos de machine learning e dados coletados em tempo real, implicando diretamente na sua capacidade de armazenamento.

O processamento pode ser feito na exportação e, dessa forma, a organização dos dados é feita na leitura. Por mais que ele seja de rápida leitura, pode armazenar tantos dados variados que acaba gerando um **pântano de dados** se não forem implementadas técnicas para manter a qualidade e a governança dos dados.

Geralmente são explorados pelos **cientistas de dados** e **analistas de BI**.

Confira o episódio de Hipsters Ponto Tube: "O que faz uma Cientista de Dados?", no qual a cientista Mikaeri Ohana conta para a gente um pouco mais sobre o seu dia a dia enquanto Data

Scientist.

https://www.youtube.com/watch?v=Zwvq-rlIHAw

Data Lake — Significado

O termo Data Lake, em inglês, pode ser traduzido para o português de forma literal, como "Lago de Dados", que faz jus ao conceito que abordamos há pouco, do pântano de dados. Por ser uma estrutura mais flexível que o Data Warehouse, o Data Lake pode acomodar uma grande variedade de dados, estruturados e não estruturados, em sua forma original.

Data Warehouse vs Data Lake: Principais diferenças

É importante compreender a diferença entre data lake e data warehouse, pois apesar de ambos serem locais de armazenamento de dados, é comum haver confusão. Tanto data warehouses quanto data lakes podem armazenar dados, mas existem diferenças em relação à escala e número de fontes de dados. Uma organização pode precisar de um data lake, data warehouse e bases de dados para diferentes usos.

Em resumo:

O Data Warehouse é um local centralizado para dados estruturados e possui características conhecidas com antecedência para a sua construção e processo de **extração, transformação e carregamento de dados**.

O Data Lake tem uma proporção muito maior onde dados de várias fontes podem se encontrar. Todos os tipos de dados são permitidos, estruturados ou não.

Confira também: O que são Data Lakes? | #AluraMais — YouTube

https://www.youtube.com/watch?v=GkhuRcHsVMk

Como criar um Data Warehouse

Leve em consideração que você precisa guardar uma grande quantidade de informações de uma empresa. O Data Warehouse é a solução ideal para esse propósito.

A criação de um Data Warehouse segue alguns passos específicos:

- Definição do objetivo: Primeiro, você precisa saber o que quer alcançar com seu Data Warehouse. Isso é como decidir o que você quer armazenar, as informações da empresa são importantes para guardar.
- Coleta de dados: Em seguida, você coleta os dados de diferentes fontes.
- Limpeza e organização dos dados: Antes de armazenar esses dados, é importante remover informações desnecessárias ou erradas. Dados nulos, ou erros de digitação são exemplos comuns em dados empresariais.
- Armazenamento: Nesta etapa podemos armazenar os dados de forma organizada no Data Warehouse.
- Uso dos dados: Por último, as informações armazenadas no Data Warehouse são usadas para análises e tomadas de decisão na empresa.

Lembre-se: criar um Data Warehouse é um processo que envolve muita tecnologia e conhecimento especializado, mas os passos básicos são como organizar qualquer coleção importante de informações.

Benefícios do Data Warehouse e Data Lake

Ao discutir os benefícios do Data Warehouse e do Data Lake, estamos falando de duas abordagens poderosas para o gerenciamento de dados, cada uma com suas vantagens únicas no mundo da análise de dados e da inteligência empresarial.

Por um lado, Data Warehouses proporcionam um ambiente altamente estruturado e organizado para armazenar dados. Esta organização facilita a realização de análises complexas e a geração de relatórios detalhados.

No contexto, por exemplo, de empresas que dependem de dados consistentes e de alta qualidade para tomar decisões estratégicas, como em finanças e operações, os Data Warehouses são inestimáveis. Eles permitem uma recuperação rápida e eficiente de dados, garantindo que as informações sejam facilmente acessíveis e confiáveis.

Por outro lado, os **Data Lakes** oferecem uma solução mais flexível e escalável para o armazenamento de dados. Eles são capazes de armazenar uma grande variedade de dados, desde estruturados até não estruturados, como textos, imagens e vídeos.

Levando em consideração o contexto de negócios, esta flexibilidade é particularmente vantajosa para organizações que lidam com grandes volumes de dados variados e que buscam insights inovadores através de análises avançadas, como aprendizado de máquina e inteligência artificial.

Em um Data Lake, os dados podem ser armazenados em seu formato original, permitindo que as organizações mantenham uma reserva rica e diversificada de informações para uma ampla gama de aplicações futuras.

Em suma, enquanto os Data Warehouses oferecem um ambiente altamente estruturado e eficiente para análise de dados históricos e estruturados, os Data Lakes se destacam por sua capacidade de armazenar enormes volumes de dados diversos, fornecendo uma base robusta para exploração de dados e inovação analítica.

Conclusão

Ao finalizar a leitura do nosso artigo, tenho certeza que você aprendeu um pouco mais sobre as principais características entre os diferentes tipos de armazenamento, suas vantagens e contextos de uso, sempre conectadas a sua realidade profissional ou de maturidade nos estudos.

Aqui na Alura você aprender mais sobre esse tema com nosso time de especialistas que vai te ajudar a alavancar sua carreira e capacitar você a tomar decisões cada vez mais estratégicas e baseadas em evidências.

Confira: "Engenharia de Dados: o que é, o que faz e um Guia completo", e pode se aprofundar no nossos cursos de Engenharia de dados:

- Introdução a Data Pipelines;
- Formação BI e Data Warehouse com Pentaho.

Além disso, temos cursos para se aprofundar em dados estruturados com o MySQL e não estruturados NoSQL.

A Engenharia de Dados está sendo **reescrita pela IA.** O momento de virar essa chave **na sua carreira** é agora.

Em **5 aulas gratuitas**, você vai construir no **Databricks** um pipeline de dados completo que transforma dados brutos

de voos em informações confiáveis e as conecta a um **agente de IA** capaz de responder **perguntas de negócio.** E leva de bônus um **eBook de Currículo e LinkedIn.**

Nome*

+55 WhatsApp*

E-mail*

Seu momento de carreira atual

Entendo que meus dados pessoais serão compartilhados com a Alura e processados de acordo com o Aviso de Privacidade.

Sucesso!

CLOUDFLARE
Privacidade • Ajuda

Quero me inscrever

Avalie este artigo ☆ ☆ ☆ ☆ ☆

A

Autor(a)

allan-spadini

Explore por tópico

Back-end Dados DevOps Front-end Gestão & Negócios

Institucionais Inteligência Artificial Mobile UX & Design

Leia também



10/11/2024

A importância da manutenção preventiva no PostgreSQL para garantir desempenho e disponibilidade

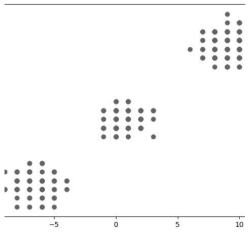
Ler mais →



04/03/2021

Gráfico de Pizza: o que é, como fazer e exemplos

Ler mais →



08/05/2019

Agrupando dados com Python

Ler mais →

Ver mais conteúdos

Inscreva-se em nossa Newsletter

Fique por dentro de conteúdos, insights e oportunidades do universo tech. Receba novidades e lançamentos direto no seu e-mail.

E-mail*

Enviar

Li e concordo com os Termos de Uso e Política de Privacidade

Institucional

- Sobre nós
- Trabalhe Conosco
- Para Empresas
- Para Escolas
- Política de Privacidade
- Compromisso de Integridade
- Termos de Uso
- Canal de Ética
- Código de Ética
- Fale Conosco
- Documentos Institucionais
- Status

A Alura

- Como Funciona
- Inteligência Artificial
- Plataforma
- Depoimentos
- Instrutores(as)
- Dev em <T>
- Luri, a Inteligência Artificial da Alura
- IA Conference
- Cursos Imersivos
- Perguntas Frequentes

Conteúdos

- Alura Cases
- Imersão Engenharia de Dados com IA
- Artigos
- Podcasts
- Artigos de educação corporativa

Uma Empresa do Grupo

ALUN

Outras empresas do Grupo Alun

FIAP STARTSE PM3 LUMINA

Novidades e lançamentos

E-mail

Enviar

Ao submeter seu e-mail, você concorda com a política de privacidade da Alura.

Redes Sociais & Apps



